

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ГОСУДАРСТВЕННЫЙ
ПЕДАГОГИЧЕСКИЙ УНИВЕРСИТЕТ им. А. И. ГЕРЦЕНА»

**институт информационных технологий и технологического образования
кафедра информационных технологий и электронного обучения**

Основная профессиональная образовательная программа
Направление подготовки 09.03.01 Информатика и вычислительная техника
Направленность (профиль) «Технологии разработки программного обеспечения»
форма обучения – очная

Курсовая работа

по дисциплине «Пакеты прикладных программ для статистической обработки
и анализа данных»

«Регрессионный анализ»

Обучающегося 3 курса

Салимова Даниила Рамильевича

Руководитель:
к.п.н.доцент
Гончарова С.В.

« _____ » _____ 2024 г.

Санкт-Петербург
2024

Оглавление

ВВЕДЕНИЕ.....	3
ТЕОРЕТИЧЕСКАЯ ЧАСТЬ	5
1.1. Введение в регрессионный анализ.....	5
1.2. Типы регрессионных моделей	6
1.3. Методы оценки модели	8
ПРАКТИЧЕСКАЯ ЧАСТЬ	10
2.1. Постановка задачи и описание данных	10
2.2. Подготовка данных.....	12
2.3. Построение модели регрессии.....	16
2.4. Оценка качества модели	18
ЗАКЛЮЧЕНИЕ	19
СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ.....	20
Приложение А.....	21

ВВЕДЕНИЕ

Актуальность

Заработная плата — это один из самых важных факторов для любого человека, так как она напрямую влияет на уровень жизни и возможности. Для многих людей важно понимать, что именно влияет на размер их зарплаты, чтобы лучше планировать своё будущее и принимать важные карьерные решения.

Одним из таких факторов считается профессиональный опыт. Логично предположить, что чем дольше человек работает в своей сфере, тем больше у него навыков и знаний, а значит, и зарплата должна быть выше. Но как именно опыт влияет на зарплату, не всегда очевидно. Это может зависеть от отрасли, уровня образования или даже экономической ситуации в стране. Поэтому важно провести исследование, чтобы понять, насколько сильна эта связь и есть ли она вообще.

Регрессионный анализ — это полезный метод, который помогает находить зависимости между разными показателями. В данном случае он позволяет изучить, как именно профессиональный опыт влияет на заработную плату. Также этот метод даёт возможность построить модель, с помощью которой можно прогнозировать уровень зарплаты, зная опыт работы.

Тема этого исследования актуальна, потому что анализ заработной платы интересен не только сотрудникам, но и работодателям. Работодатели хотят понять, как справедливо устанавливать зарплаты, чтобы привлекать хороших специалистов, а сотрудники хотят знать, какие факторы помогут им увеличить доход. В этой работе будет рассмотрена связь между профессиональным опытом и заработной платой с помощью регрессионного анализа, а также сделаны выводы, которые могут быть полезны для практического применения.

Цель и задачи

Цель данной курсовой работы заключается в построении линейной регрессии на основе данных о заработной плате и опыта работы. Для достижения этой цели были поставлены следующие задачи:

1. Изучить регрессионный анализ.
2. Рассмотреть поставленную задачу в контексте решения ее в программе Knime.
3. Построить регрессионную модель и оценить ее качество.

Объект исследования: построение линейной регрессии в программе Knime.

ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

1.1. Введение в регрессионный анализ

Регрессионный анализ — набор методов, которые оценивают связь между несколькими переменными с помощью построения математических моделей. Они определяют, как изменения одного параметра влияют на другой. Наиболее распространённый вид регрессионного анализа — линейная регрессия, когда находят линейную функцию, которая, согласно определённым математическим критериям, наиболее соответствует данным. Например, в методе наименьших квадратов вычисляется прямая (или гиперплоскость), сумма квадратов между которой и данными минимальна.

1. Определение степени детерминированности вариации критериальной (зависимой) переменной предикторами (независимыми переменными)
2. Предсказание значения зависимой переменной с помощью независимой(-ых)
3. Определение вклада отдельных независимых переменных в вариацию зависимой

Регрессионный анализ активно используется в бизнесе, государственном управлении, некоммерческих организациях и других сферах. Вот примеры, где он помогает оценить влияние различных факторов на ключевые показатели:

- в торговле — определяет, какие факторы влияют на спрос в магазине и как привлечь больше покупателей;
- в маркетинге — анализирует, что влияет на посещаемость, популярность контента и эффективность рекламных кампаний;
- в экономике — выявляет параметры, оказывающие наибольшее влияние на экономические процессы и показатели;
- в научной сфере — помогает, например, определить влияние метана на изменение климата;

- в медицине — оценивает риск возникновения болезней и шансы на выздоровление пациентов.

1.2. Типы регрессионных моделей

Одиночная линейная регрессия. Классический метод, при котором оценивают зависимость одной переменной от другой. Такую зависимость можно описать прямой линией, а уравнение регрессии имеет вид:

$$y = a + bx + \varepsilon$$

Здесь y — зависимая переменная, x — независимая, a и b — коэффициенты регрессии, ε — случайные ошибки. Кроме a и b , коэффициенты могут также обозначать буквой β : β_1 , β_2 и так далее.

Множественная линейная регрессия. Здесь взаимосвязь также описывается прямой линией, но независимых переменных несколько. Уравнение для множественной регрессии выглядит так:

$$y = a + b_1x_1 + b_2x_2 + \dots + \varepsilon$$

Видно, что переменных x , то есть независимых, несколько. Коэффициентов b , которые умножаются на x , тоже несколько. В таком виде уравнение описывает гиперплоскость в многомерном пространстве, где каждая переменная добавляет измерение. Это позволяет учитывать влияние нескольких факторов на зависимую переменную одновременно.

Одиночная полиномиальная регрессия. Это один из распространенных видов нелинейной регрессии, где зависимость нельзя описать прямой линией. График в этом случае представляет собой полином — сумму степеней независимой переменной, умноженных на коэффициенты. Формула выглядит следующим образом:

$$y = a + b_1x + b_2x^2 + \dots + b_nx^n + \varepsilon$$

Здесь используется только одна независимая переменная x , но она возводится в разные степени, чтобы описать более сложную зависимость.

В этой курсовой работе будет рассмотрен первый тип — одиночная линейная регрессия.

Мультиколлинеарность — это явление, при котором одна из входных переменных статистической модели (например, множественной линейной регрессии) линейно зависит от других входных переменных, т.е. между ними

наблюдается сильная корреляция. В этой ситуации оценки коэффициентов (параметров) модели могут случайно и значительно изменяться даже при небольших изменениях в исходных данных, т.е. решение становится неустойчивым. Это значит, что для построения модели регрессии необходимо выбрать не только такие независимые переменные, которые имеют корреляцию с зависимой переменной, но и такие, которые не коррелируют с собой.

Корреляционная зависимость — статистическая взаимосвязь двух или более случайных величин (либо величин, которые можно с некоторой допустимой степенью точности считать таковыми), при этом изменения значений одной или нескольких из этих величин сопутствуют систематическому изменению значений другой или других величин.

Математической мерой корреляции двух случайных величин служит корреляционное отношение либо коэффициент корреляции R . В случае если изменение одной случайной величины не ведёт к закономерному изменению другой случайной величины, но приводит к изменению другой статистической характеристики данной случайной величины, то подобная связь не считается корреляционной, хотя и является статистической.

1.3. Методы оценки модели

Оценка качества показывает, насколько теоретические вычисления по построенной модели отклоняются от экспериментальных данных. Существует множество методов оценки модели, вот несколько из них:

Среднеквадратическое отклонение - наиболее распространённый показатель рассеивания значений случайной величины относительно её математического ожидания (аналога среднего арифметического с бесконечным числом исходов). Обычно означает квадратный корень

из дисперсии случайной величины, но иногда может означать тот или иной вариант оценки этого значения.

$$S_{\bar{x}} = S_0 / \sqrt{n} = \sqrt{\frac{1}{n(n-1)} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Коэффициент детерминации (R^2) — это доля дисперсии зависимой переменной, объясняемая рассматриваемой моделью зависимости, то есть объясняющими переменными. Более точно — это единица минус доля необъяснённой дисперсии (дисперсии случайной ошибки модели, или условной по факторам дисперсии зависимой переменной) в дисперсии зависимой переменной. Его рассматривают как универсальную меру зависимости одной случайной величины от множества других.

$$R^2 = 1 - \frac{D[y|x]}{D[y]} = 1 - \frac{\sigma^2}{\sigma_y^2},$$

В статистике **средняя абсолютная ошибка** — это мера ошибок между парными наблюдениями, выражающими одно и то же явление. Примеры Y и X включают сравнение прогнозируемого и наблюдаемого, последующего времени с начальным временем, а также сравнения одного метода измерения с альтернативным методом измерения.

$$\text{MAE} = \frac{\sum_{i=1}^n |y_i - x_i|}{n} = \frac{\sum_{i=1}^n |e_i|}{n}.$$

ПРАКТИЧЕСКАЯ ЧАСТЬ

2.1. Постановка задачи и описание данных

Для изучения регрессионного анализа и модели регрессии была составлена задача и набор данных для нее. Необходимо построить регрессионную модель для значений заработной платы относительно количества лет опыта работника и определить зависимость между опытом работы и заработной платой. Снизу представлены данные. Даны 30 строк со значением опыта работы и фактической зарплаты сотрудника. Таким образом,

для опыта работы в 1,1 года зарплата соответствует 39343, для трех лет – 60150. Соответственно необходимо построить регрессионную модель, чтобы в том числе предсказать заработную плату для других значений опыта работы. Данные являются абстрактными и тренировочными, поэтому на модель не будут влиять другие факторы, как актуальность должности, ее востребованность и т.д..

YearsExperience	Salary
1,1	39343
1,3	46205
1,5	37731
2	43525
2,2	39891
2,9	56642
3	60150
3,2	54445
3,2	64445
3,7	57189
3,9	63218
4	55794
4	56957
4,1	57081
4,5	61111
4,9	67938
5,1	66029
5,3	83088
5,9	81363
6	93940
6,8	91738
7,1	98273

7,9	101302
8,2	113812
8,7	109431
9	105582
9,5	116969
9,6	112635
10,3	122391
10,5	121872

Задача будет рассмотрена и решена в программе Knime Analytics Platform.

2.2. Подготовка данных

Перед работой с данными необходимо подготовить данные: нормализовать их в случае, если есть значения с разной структурой, к примеру бинарные значения или значения, выбивающиеся из диапазона значений зависимой переменной. В нашей задаче только одна независимая переменная, она в нормализации не нуждается.

Далее необходимо проверить и удалить выбросы. Для этого есть узел в Knime, называемый Box Plot. Присоединив значения из таблицы с данными к этому узлу, можно увидеть график распределения значений.




Рисунок 1




Рисунок 2

Box Plot строится следующим образом: сама ячейка идет от нижнего квартиля ($Q1$) до верхнего квартиля ($Q3$). Медиана рисуется как горизонтальная полоса внутри ячейки. Расстояние между $Q1$ и $Q3$ называется межквартильным размахом (IQR).

Выше и ниже ячейки находятся так называемые усы. Они рисуются на минимальном и максимальном значении как горизонтальные полосы и соединяются с ячейкой линией. Усы никогда не превышают $1,5 * IQR$. Это означает, что если есть некоторые точки данных, которые превышают либо $Q1 - (1,5 * IQR)$, либо $Q3 + (1,5 * IQR)$, то усы рисуются точно в этих диапазонах, а точки данных рисуются отдельно как выбросы. В нашем случае точек нет, значит нет и выбросов.

В узле Statistics можно найти такие характеристики данных как коэффициент эксцесса – мера остроты пика распределения случайной величины, ковариацию – мера зависимости двух случайных величин.

Также важно построить гистограммы значений, чтобы оценить распределение данных, в случае если они сильно отклонены от нормального, подсчет коэффициентов и построение модели будет сложным, и придется прибегать к инструментам, чтобы привести данные в более удобный вид. В




Рисунок 3




Рисунок 4

узле Density Plot и Histogram как и можно построить эти гистограммы. Выглядят они следующим образом:

#	RowID	Column	Min	Max	Mean	Std. devia...	Variance	Skewness	Kurtosis	Overall su...	No. missi...	No. NaNs	No. +*s	No. -*s	Me
1	Year...	YearsExperi...	1.1	10.5	5.313	2.838	8.054	0.38	-1.012	159.4	0	0	0	0	
2	Salary	Salary	37,731	122,391	76,003	27,414.43	751,550,960...	0.354	-1.295	2,280,090	0	0	0	0	

Рисунок 5

Далее важным шагом является построение корреляционной матрицы для переменных. В этой матрице оценивается связь всех переменных друг с другом. Значения коэффициента находятся в диапазоне от нуля до единицы. Значения выше 0,8 являются положительными значениями и свидетельствуют о наличии корреляционной связи двух переменных. В Knime используется узел Linear Correlation для этого. На рисунке 4 видны значения коэффициента корреляции, которые явно являются положительными.

#	RowID	YearsExperience	Salary
1	Year...	1	0.978
2	Salary	0.978	1

Рисунок 6

В узле Partitioning данные делятся на две группы: обучающую и тестовую выборки в соотношении 70% на 30%. Далее первая группа будет использоваться в обучении модели и присвоении коэффициентов уравнения, а вторая в тестировании модели, что предсказывает значения зар. платы для новых значений лет опыта работы.




Рисунок 7

2.3. Построение модели регрессии


Для вывода коэффициентов уравнения регрессии в KNIME используется узел Linear Regression Learner. Он принимает обучающую выборку и выводит результат в таблице (рисунок 8)

☐	#	RowID	Variable <i>String</i>	Coeff. <i>Number (double)</i>
☐	1	Row1	YearsExperience	9,698.295
☐	2	Row2	Intercept	23,298.259

Рисунок 8

Таким образом коэффициент $b_1 = 9698,295$, а $b_0 = 23298,259$ и уравнение выглядит следующим образом: $Y = 23239,259 + 9698,295x_1 + \varepsilon_i$.

Далее в узел Regression Predictor отправляются данные тестовой



выборки с подключением коэффициентов, полученных ранее.

Рисунок 9

В этом узле мы получаем новые значения, которые являются

☐	#	RowID	YearsExperience Number (double)	Salary Number (integer)	Prediction (Salary) Number (double)
☐	1	Row0	1.1	39343	33,966.383
☐	2	Row5	2.9	56642	51,423.315
☐	3	Row6	3	60150	52,393.145
☐	4	Row7	3.2	54445	54,332.804
☐	5	Row8	3.2	64445	54,332.804
☐	6	Row13	4.1	57081	63,061.27
☐	7	Row17	5.3	83088	74,699.224
☐	8	Row20	6.8	91738	89,246.667
☐	9	Row24	8.7	109431	107,673.428

Рисунок 10

предсказанием, прогнозом данных с полученными коэффициентами. И выглядят они следующим образом:

В этой таблице (рисунок 10) можно сравнить реальные значения заработной платы с прогнозируемыми. Они разнятся и отличаются друг от друга на разные значения.

В узле Line Plot можно увидеть построенную регрессионную модель относительно изначальных данных (рисунок 11)




Рисунок 11

2.4. Оценка качества модели

С помощью узла Numeric Scorer можно оценить нашу новую модель регрессии. В этой таблице (рисунок 11) есть такие метрики как R^2 , RMSE, MAE, то есть коэффициент детерминации, среднее квадратичное отклонение и среднюю абсолютную ошибку.

☐	#	RowID ↓	Prediction (Salary) Number (double)
☐	1	R^2	0.913
☐	2	mean absolute error	5,243.833
☐	3	mean squared error	37,112,396.164
☐	4	root mean squared error	6,091.994
☐	5	mean signed difference	-3,914.884
☐	6	mean absolute percentage error	0.085
☐	7	adjusted R^2	0.913

Рисунок 11

Мы знаем, что коэффициент детерминации для модели с константой принимает значения от 0 до 1 и чем ближе значение к 1, тем сильнее зависимость. Значит можем утверждать, что наша модель соответствует данным.

ЗАКЛЮЧЕНИЕ

В ходе выполнения курсовой работы была исследована взаимосвязь между профессиональным опытом и уровнем заработной платы с использованием методов регрессионного анализа. В процессе работы удалось не только изучить основные теоретические аспекты регрессионного анализа, но и применить их на практике для построения и оценки модели, основанной на реальных данных.

На основании проведённого анализа было установлено, что существует прямая зависимость между опытом работы и заработной платой. Полученная регрессионная модель продемонстрировала высокое значение коэффициента детерминации (R^2), что подтверждает её способность объяснять значительную часть вариации заработной платы с учётом опыта работы. Однако было также выявлено, что на уровень заработной платы могут влиять и другие факторы, такие как отрасль, регион, образование и навыки, которые в данной работе не рассматривались.

В заключение можно отметить, что исследование достигло своей цели: была изучена зависимость между опытом работы и заработной платой, а также

проведён анализ качества модели. В дальнейшем можно продолжить работу, добавив дополнительные факторы, влияющие на заработную плату, чтобы создать более точную и комплексную модель.

СПИСОК ИСПОЛЬЗУЕМЫХ ИСТОЧНИКОВ

1. <https://www.kaggle.com/> сайт с набором данных
2. Гусев А.В., Иванов П.А. Основы статистики и регрессионного анализа. — М.: Юрайт, 2020.
3. Савельев А.В., Мухин А.С. Эконометрика: Учебное пособие. — СПб.: Питер, 2019.
4. Официальный сайт KNIME: описание возможностей платформы для анализа данных. URL: <https://www.knime.com> (дата обращения: 19.12.2024).
5. Справочные материалы по статистическим методам: Корреляция и регрессия. URL: <https://statsoft.ru/home/textbook/default.aspx> (дата обращения: 19.12.2024).

Приложение А

Ссылка на диск с файлом Knime Analytics Platform -
https://drive.google.com/drive/folders/1i7zX71eR_ASLECTD6H7Z1gpq2jV-JiFFD?usp=sharing