

Задание 1 (инвариантное)

Базы данных, банки данных, Big Data и СУБД

Основные понятия

Что такое база данных

База данных - это организованная совокупность взаимосвязанных данных, предназначенная для длительного хранения, поиска, обновления и совместного использования. В базе данных сведения структурируются по выбранной модели: реляционной, документной, графовой, ключ-значение, колоночной и др.

Главная особенность базы данных состоит в том, что данные отделены от прикладных программ. Это позволяет использовать одни и те же данные разными приложениями, снижать дублирование и поддерживать целостность информации.

Что такое банк данных

Банк данных - это более широкое понятие, чем база данных. Под банком данных обычно понимают организационно-техническую систему, включающую одну или несколько баз данных, СУБД, аппаратные средства, программные средства, администраторов, пользователей, регламенты доступа, резервного копирования и защиты информации.

Иными словами, база данных является ядром информационного ресурса, а банк данных описывает всю среду, в которой этот ресурс создается, обслуживается и используется.

Отличие базы данных от банка данных

Отличие можно представить через уровень рассмотрения. База данных отвечает на вопрос: «какие данные и как они организованы?». Банк данных

отвечает на вопрос: «какая система обеспечивает сбор, хранение, обработку, безопасность и предоставление этих данных пользователям?».

Критерий	База данных	Банк данных
Состав	Организованная совокупность взаимосвязанных данных.	База/базы данных + СУБД + программно-аппаратные средства + персонал + регламенты + метаданные.
Назначение	Хранение и предоставление данных прикладным программам и пользователям.	Комплексное информационное обеспечение организации или предметной области.
Управление	Обычно управляется СУБД.	Управляется как организационно-техническая система: администрирование, безопасность, обслуживание, политика доступа.
Пример	Таблицы клиентов и заказов в PostgreSQL.	Корпоративный информационный ресурс: хранилище клиентов, серверы, СУБД, администраторы, инструкции, резервное копирование.

Что такое СУБД

Система управления базами данных (СУБД) - это программное обеспечение, которое управляет хранением, организацией, защитой, обновлением и извлечением данных. СУБД предоставляет пользователям и приложениям язык запросов, механизмы транзакций, средства администрирования, управления доступом и восстановления после сбоев.

Примеры СУБД: PostgreSQL, MySQL, Oracle Database, Microsoft SQL Server, MongoDB, ClickHouse, Apache Cassandra, Redis. В зависимости от назначения СУБД могут быть транзакционными (OLTP), аналитическими (OLAP), распределенными, встраиваемыми или специализированными под определенный тип данных.

Что такое Big Data

Big Data (большие данные) - это массивы данных, объем, скорость поступления и разнообразие которых превышают возможности традиционных средств хранения и обработки. Для Big Data характерны признаки 5V: volume (объем), velocity (скорость), variety (разнообразие), veracity (достоверность) и value (ценность).

Большие данные могут включать транзакции, логи, телеметрию, текстовые документы, изображения, данные геолокации, события из мобильных приложений, показания датчиков и потоки из социальных сетей. Для работы с ними применяют распределенное хранение, параллельную обработку, потоковые платформы, data lake, lakehouse и облачные сервисы.

Что такое аналитика больших данных

Аналитика больших данных - это совокупность методов, инструментов и процессов, с помощью которых из больших, разнообразных и быстро меняющихся наборов данных извлекаются закономерности, прогнозы и управленческие выводы. Она объединяет статистику, машинное обучение, визуализацию, инженерную подготовку данных и предметную экспертизу.

Типовой конвейер Big Data-аналитики включает сбор данных, очистку и нормализацию, хранение в data lake или хранилище данных, пакетную либо потоковую обработку, построение моделей, визуализацию результатов и внедрение решений в бизнес-процессы.

Поставщики Big Data в России

Российский рынок Big Data и ИИ быстро развивается: по данным Ассоциации больших данных, Б1 и TAdviser, к 2024-2025 годам объем рынка превысил 430 млрд руб., а годовые темпы роста оценивались на уровне 25-35%. Ниже приведены примеры поставщиков, которые предлагают платформы, облачные сервисы, BI, data lake, потоковую обработку или аналитические продукты.

Компания	Продукты/направления	Краткая характеристика	Типовые сценарии
Яндекс Cloud	Yandex Data Processing, DataLens, Managed Service for ClickHouse/Kafka	Управляемые кластеры Hadoop и Spark, интеграция с Object Storage, Kafka, ClickHouse; облачная модель PaaS.	Облачные data lake, ETL/ELT, пакетная обработка, BI-визуализация.
VK Cloud	Облачные сервисы данных и аналитики	Инфраструктура и управляемые сервисы для хранения, обработки и анализа данных; сценарии импортозамещения.	Корпоративная аналитика, хранилища данных, ML-проекты.
Cloud.ru	Облачная платформа и AI/data-сервисы	Провайдер облачных сервисов и технологий ИИ; развитие платформенных решений для enterprise-заказчиков.	Data platform, облачные вычисления, аналитические витрины.
MTC Web Services	MWS Data	Платформа 2025 года для хранения,	Крупный и средний бизнес,

Компания	Продукты/направления	Краткая характеристика	Типовые сценарии
		обработки, визуализации, контроля качества и безопасности данных; работа с потоковыми и историческими массивами.	real-time и batch-аналитика.
Arenadata	Arenadata Hyperwave, Arenadata DB, Streaming, Orchestrator	Российская enterprise-платформа для хранения, обработки и анализа данных любого объема; поддержка lakehouse/data mesh и потоковой обработки.	Петабайтные хранилища, потоковая аналитика, корпоративные DWH.
Форсайт	Foresight Analytics Platform	BI- и аналитическая платформа для отчетности, визуализации, моделирования, прогнозирования и Data Mining.	Госсектор и крупный бизнес: управленческая отчетность, продвинутая аналитика.
Loginom	Low-code аналитическая платформа Loginom	Среда для подготовки данных, построения аналитических процессов и моделей без глубокого программирования.	Data preparation, скоринг, прогнозирование, маркетинговая аналитика.
МегаФон / oneFactor	Геоаналитика и Big Data-аналитика на телеком-данных	Аналитические продукты на обезличенных данных мобильной сети и внешних источниках.	Ритейл, транспорт, городская аналитика, маркетинг.

Перечень не является рейтингом: компании различаются по специализации. Одни поставщики предлагают облачную инфраструктуру и управляемые кластеры, другие - аналитические приложения, BI-платформы или отраслевые продукты на обезличенных данных.

Поставщики Big Data в мире

На мировом рынке Big Data ведущую роль играют глобальные облачные провайдеры, производители СУБД, платформы lakehouse, поставщики BI и гибридных data platform. Их решения часто объединяют хранение, потоковую обработку, машинное обучение, управление доступом, каталогизацию данных и визуализацию.

Компания	Продукты/направления	Краткая характеристика	Типовые сценарии
Amazon Web Services	Amazon EMR, Redshift, Kinesis, Glue, S3	Широкий стек управляемых сервисов для потоков, data lake, DWH, ETL и ML.	Cloud-native big data, streaming, lakehouse.
Microsoft	Microsoft Fabric, Azure Synapse, Azure HDInsight, Power BI	Единая SaaS-платформа аналитики с OneLake, Data Factory, Data Engineering, Real-Time Intelligence и BI.	End-to-end аналитика, корпоративный BI, lakehouse.
Google Cloud	BigQuery, Dataproc, Dataflow, Pub/Sub, Looker	BigQuery как автономная data/AI-платформа; Dataproc для Spark/Hadoop.	DWH, ML/AI-аналитика, потоковая и пакетная обработка.
Oracle	Oracle Big Data Service, Autonomous Database, OCI Data Flow	Управляемый Hadoop-сервис, интегрированный с Oracle Database и облаком OCI.	Корпоративные данные, гибридные базы и big data workloads.
IBM	watsonx.data, Db2, Cloud Pak for Data	Гибридный открытый lakehouse для AI и BI с управлением доступом и governance.	Гибридные data lakehouse, ИИ, аналитика.
SAP	SAP Datasphere, SAP HANA Cloud, SAP Analytics Cloud	Business data fabric для доступа к бизнес-данным с сохранением контекста.	Аналитика ERP/корпоративных процессов, data fabric.
Snowflake	Snowflake AI Data Cloud	Серверная managed-платформа для data engineering, приложений, аналитики, governance и AI.	Cloud DWH, data sharing, AI/ML workflows.
Databricks	Data Intelligence Platform, Delta Lake, MLflow	Единая платформа для данных, аналитики и ИИ; lakehouse-подход.	Data engineering, ML, streaming, lakehouse.
Cloudera	Cloudera Data Platform	Гибридная платформа данных и ИИ для облаков, ЦОД и edge с единым governance.	Гибридные Hadoop/Spark-экосистемы, enterprise data lifecycle.
Teradata	VantageCloud	Облачная аналитическая data platform для масштабной аналитики на AWS, Azure и	Высоконагруженные DWH и advanced analytics.

Компания	Продукты/направления	Краткая характеристика	Типовые сценарии
		Google Cloud.	

Технические характеристики баз данных

Технические характеристики базы данных определяют, насколько хорошо она подходит для конкретной задачи: учетных операций, веб-приложений, аналитики, потоковой обработки, машинного обучения или архивного хранения. При выборе СУБД важно учитывать не только скорость, но и надежность, безопасность, масштабируемость, стоимость владения и совместимость с существующей инфраструктурой.

Характеристика	Возможные значения/показатели	Практическое значение
Модель данных	Реляционная, документная, графовая, ключ-значение, колоночная, временные ряды, объектно-реляционная.	Определяет структуру хранения и типы запросов; реляционная модель удобна для строгих транзакций, NoSQL - для гибкости и масштабирования.
Язык запросов и API	SQL, Cypher, Gremlin, MongoDB Query Language, REST/GraphQL/JDBC/ODBC.	Влияет на переносимость решений, сложность разработки и интеграцию с BI/ETL.
Транзакционность	ACID, BASE, уровни изоляции, журналы транзакций.	Критична для банковских, учетных и ERP-систем; в аналитике иногда уступает место скорости и масштабированию.
Масштабирование	Вертикальное, горизонтальное, шардинг, репликация, разделение compute/storage.	Big Data-системы чаще требуют горизонтального масштабирования на кластерах.
Производительность	TPS/QPS, латентность, пропускная способность, оптимизатор запросов, индексы.	Оценивается на типовых нагрузках: OLTP, OLAP, streaming, mixed workloads.
Надежность и отказоустойчивость	Репликация, quorum, автоматическое восстановление, backup/restore, disaster recovery.	Определяет допустимое время простоя и потери данных: RTO/RPO.
Безопасность	Аутентификация, авторизация, RBAC/ABAC, шифрование, аудит, маскирование данных.	Особенно важна при персональных данных, коммерческой тайне и регуляторных требованиях.
Согласованность данных	Strong, eventual, causal consistency; CAP trade-offs.	Выбор зависит от требований к точности данных и доступности системы.
Интеграция и экосистема	ETL/ELT, Kafka, Spark, Airflow, BI, ML-фреймворки, коннекторы.	Чем богаче экосистема, тем проще строить аналитические конвейеры.
Администрирование	Мониторинг, автотюнинг, управление ресурсами, observability, FinOps.	Снижает эксплуатационные затраты и риски деградации качества данных.

Сравнение типов баз данных

Тип БД	Примеры	Особенности	Сферы применения
Реляционные	PostgreSQL, Oracle Database, MySQL, MS SQL Server	Строгая структура таблиц, SQL, транзакции ACID.	Финансы, учет, ERP, CRM.
Документные	MongoDB, Couchbase	Хранение JSON/BSON-документов, гибкая схема.	Каталоги, мобильные приложения, контент.
Ключ-значение	Redis, Amazon DynamoDB	Быстрый доступ по ключу, простая модель.	Кэш, сессии, профили пользователей.
Колоночные/аналитические	ClickHouse, Cassandra, BigQuery, Redshift	Оптимизация для больших объемов и аналитических запросов.	Логи, витрины данных, BI, телеметрия.
Графовые	Neo4j, Amazon Neptune	Хранение связей как объектов первого класса.	Социальные графы, рекомендации, fraud detection.
Временные ряды	InfluxDB, TimescaleDB	Оптимизация для данных, привязанных ко времени.	IoT, мониторинг, финтех-котировки.